

DAY 1 · 분석 보고서

배터리 수명 사전 예측

EDA & 모델 전략 수립

Batch 1 + Batch 2 + Batch 3 · 탐색적 데이터 분석과 회귀 모델 설계

The logo for SKALA, featuring the word "SKALA" in a bold, white, sans-serif font. The letter "K" is stylized with a purple and blue geometric shape integrated into its structure.

울산 1반 U018 원종현

CONTENTS

목차

탐색적 데이터 분석 및 모델 설계 전략

구분	주요 내용	페이지
분석 결과 요약	Q1-Q5 주요 결론 · 초기 수명 예측의 모델 전략	3
데이터 구성 및 전처리	Cell 필드 · Summary/Cycles 구조 · 수명 라벨 및 전처리 기준	4-7
Question 1 · Cycle Life 분포	수명 분포와 장·단수명 비율 · 최단수명 사례 · 누적분포 및 집단 차이	8-10
Question 2 · 열화 곡선과 Knee	사이클별 방전 용량 · 초기 증감 · Knee 탐색 · 전후 감소 속도	11-13
Question 3 · ΔQ(V) 곡선	cycle 100-10 차분 · 수명 그룹 비교 · 통계값 및 전압 구간별 해석	14-16
Question 4 · 충전 조건과 수명	프로토콜별 수명 · 유효 C-rate · 실측 전류 · 태그별 상세 비교	17-20
Question 5 · 상관관계와 공선성	초기 신호와 수명 상관 · VIF · 배치 차이 보정 · 신호의 독립성	21-23
모델 설계 전략	EDA 종합 · 회귀 목표 및 피처 · 데이터 처리 · 후보 모델과 검증	24-26
부록 및 참고문헌	제외 셀 목록 · 측정 품질 · 통계 분석 방법 · 참고문헌	27-28

EXECUTIVE SUMMARY

분석 결과 요약

배치별 EDA의 주요 결론 및 모델 설계 방향

본 분석은 세 배치의 초기 사이클 기록과 전체 열화 궤적을 비교하여, cycle 100 시점의 정보로 최종 수명을 예측하기 위한 모델 전략을 도출하였다. 원시 139개 셀 중 수명 라벨·측정 품질을 점검한 118개 셀(B1 36개, B2 39개, B3 43개)을 주 분석 대상으로 사용하였다.

Question 1 · Cycle Life 분포

수명 중앙값은 B1 772.5, B2 472, B3 1,002 cycles로 배치별 차이가 크다. 단수명(<500) 28개는 모두 B2에 속하고, 장수명(>1,000)은 전체 30개 중 B3에 22개가 집중된다. B2의 분포는 짧은 수명 집단과 newstructure 태그 집단의 긴 수명이 혼재해 오른쪽 꼬리를 보인다. 배치 내부 IQR 기준의 저수명 이상치는 없으며, 최단수명 사례를 측정 오류로 간주해 삭제할 근거는 부족하다.

Question 2 · 열화 곡선 및 Knee point

118개 중 93개(78.8%)는 Qd(100)이 Qd(2)보다 높아, 초기 용량 감소만으로 최종 수명을 설명하기 어렵다. 전체 궤적에서는 중반의 완만한 감소 이후 후기에 감소 속도가 가속된다. 구간 회귀 기준을 만족한 117개 셀의 Knee는 배치별 수명 대비 중앙값 약 75~79%에 위치한다. Knee 전후 기울기 비 중앙값은 약 10배로, 일정한 감소율을 가정하는 직선 외삽과 맞지 않는다.

Question 3 · 초기 $\Delta Q(V)$ 곡선

동일한 1,000점 전압축에서 $Q_{100}(V) - Q_{10}(V)$ 를 계산하면, 짧은 수명 셀은 같은 배치의 긴 수명 셀보다 음의 변화와 곡선 굴곡이 크게 나타난다. log 분산과 수명의 전체 Spearman ρ 는 -0.885이며, 배치 내부에서도 -0.709~-0.826으로 강한 음의 관계를 유지한다. 평균·최솟값도 수명과 관련되지만 분산과 높은 중복성이 있다. B1·B3에는 절대 기준 단수명 셀이 없어 배치 내부 사분위 그룹을 보조 비교하였다.

Question 4 · 충전 조건과 수명

최대 C-rate만으로 수명을 설명할 수 없다. B1의 8C(15%)~3.6C 정책은 평균 1,008.5 cycles지만 8C(35%)~3.6C는 607.5로, 고전류 적용 구간에 따른 차이가 관측된다. B2에서는 같은 숫자 정책의 태그별 평균 수명이 약 1.8~2.2배 차이 난다. 실측 평균 전류와 수명의 관계도 B1 -0.446, B2 +0.406, B3 -0.119로 달라, 충전 조건과 셀 집단의 차이를 함께 고려해야 한다.

Question 5 · 상관관계 및 다중공선성

배치 보정 후에도 ΔQ log 분산의 순위 상관은 -0.835로 유지된다. 반면 Qd(2)는 전체 -0.563에서 보정 후 +0.011로 약해져, 초기 용량의 전체 상관이 배치 차이의 영향을 받음을 보여준다. log 표준편차는 log 분산의 정확한 선형 변환이며, ΔQ 평균·최솟값도 서로 높은 공선성을 보인다. 내부저항·온도·전류 신호의 단변량 관계는 ΔQ 분산보다 약하다.

모델 전략

예측 목표는 $\log_{10}(\text{Cycle Life})$ 회귀로 설정한다. ΔQ log 분산 단일 피쳐 모델을 기준으로 용량·저항·온도·전류 피쳐의 추가 기여를 검증하고, Ridge/Elastic Net 및 제한된 복잡도의 비선형 모델을 비교한다. 배치 외 일반화와 동일 정책 반복의 영향을 구분하기 위해 배치 보류 및 정책 그룹 평가를 실시한다. 전체 수명에서 얻은 Knee·후기 기울기는 입력에서 제외하고, 대치·표준화·피쳐 선정은 학습 fold 내부에서 수행한다.

DATA AUDIT / CELL STRUCTURE

Cell 데이터 구조 및 주요 필드

MATLAB struct의 논리적 계층과 Python dict 형태의 해석

하나의 배치는 여러 cell로 구성되며, 각 cell은 식별·충전 조건·수명 정보와 두 개의 하위 구조인 `summary`, `cycles` 를 포함한다. 원본은 MATLAB v7.3 형식으로, Python에서 HDF5 참조를 역참조하면 다음과 같은 dict 형태로 해석할 수 있다.

```
batch
└─ cell
    ├── cycle_life      수명 라벨
    ├── policy          충전 정책 코드
    ├── policy_readable 읽기 쉬운 충전 정책
    ├── barcode         셀 식별 메타데이터
    ├── channel_id      측정 채널 메타데이터
    ├── Vdlin           공통 방전 전압축
    ├── summary         사이클별 요약값의 dict
    └─ cycles           사이클 내부 곡선의 dict
```

필드	의미	데이터 타입 / 형태	단위	실제 데이터 예시
cycle_life	EOL 수명 라벨	float64 (1, 1)	cycles	477
policy	충전 정책 코드	uint16 문자 배열 디코딩 후 str	—	5_2C_58PER_4C
policy_readable	충전 정책 표시	uint16 문자 배열 디코딩 후 str	C · % SOC	5.2C(58%)-4C
barcode	셀 식별 메타데이터	uint32 (1, 6)	—	[3707764736, 2, 1, 1, 1, 1]
channel_id	측정 채널 메타데이터	uint32 (1, 6)	—	[3707764736, 2, 1, 1, 48, 1]
Vdlin	공통 방전 전압축	float64 (1, 1000)	V	[3.5, 3.498498, 3.496997, ...]
summary	사이클별 요약값 8개 하위 필드	MATLAB struct HDF5 group / dict	필드별 상이	cycle, QDischarge, IR, ...
cycles	사이클 내부 곡선 9개 하위 필드	MATLAB struct HDF5 group / dict	필드별 상이	t, I, V, Qdlin, ...

예시는 B2-C01의 원본 값이다. '—'는 물리적 단위가 없는 필드, '...'는 배열의 나머지 항목 생략을 뜻한다. 숫자는 표시 자릿수를 반올림하였다. 충전 정책의 C는 C-rate, %는 전류 전환 시점의 SOC를 나타낸다.

참조 구조 및 메타데이터 해석

`batch['summary']` 와 `batch['cycles']` 는 cell별 HDF5 참조를 가지며, 참조 대상 group 안에 실제 하위 필드가 저장된다.

`barcode` 와 `channel_id` 의 6개 정수는 MATLAB 메타데이터 저장 표현이다. 예시 배열을 단일 ID나 채널 번호로 직접 해석하지 않았으며 모델 입력에서도 제외하였다.

DATA AUDIT / SUMMARY STRUCTURE

Summary 필드의 타입·단위 및 데이터 예시

사이클별 요약값의 구조와 실제 관측값

summary 는 사이클 번호, 용량, 저항, 온도, 충전 시간을 담은 8개 필드로 구성된다. 관측 사이클 수가 N이면 각 필드는 원본에서 float64 (1, N) 배열이며, Python에서는 길이 N의 수치 배열로 펼쳐 사용한다.

필드	의미	데이터 타입 / 형태	단위	실제 데이터 예시
cycle	사이클 번호	float64 (1, N)	cycles	[10, 11, 12, ...]
QDischarge	최종 방전 용량	float64 (1, N)	Ah	[1.10372, 1.10523, 1.10627, ...]
QCharge	최종 충전 용량	float64 (1, N)	Ah	[1.09823, 1.09844, 1.09784, ...]
IR	내부저항	float64 (1, N)	Ω	[0.0174224, 0.0171992, 0.0172153, ...]
Tmin	사이클 내 최소 온도	float64 (1, N)	°C	[29.7668, 30.2133, 29.4135, ...]
Tmax	사이클 내 최대 온도	float64 (1, N)	°C	[35.067, 35.1197, 34.7975, ...]
Tavg	사이클 내 평균 온도	float64 (1, N)	°C	[31.6735, 31.9653, 31.8704, ...]
chargetime	충전 시간	float64 (1, N)	min	[10.1725, 10.1723, 10.1729, ...]

예시는 B2-C01의 cycle 10·11·12 순서이며, 해당 셀의 N은 496이다. 사이클 번호도 원본에서는 float64로 저장되지만 의미상 정수 번호다.

동일 인덱스의 사이클 대응

각 배열의 같은 인덱스는 같은 사이클을 나타낸다. 예를 들어 cycle[9]=10 과 대응하는 QDischarge[9]=1.1037184 Ah 는 cycle 10의 최종 방전 용량이다. IR[9]=0.017422387 Ω 는 같은 사이클의 내부저항이다. 초기 사이클 피쳐는 이 대응을 확인한 뒤 추출하였다.

요약값의 분석 활용

QDischarge는 전체 열화 궤적과 초기 용량 변화에 사용하며, IR은 저항 수준과 변화량, Tmin·Tmax·Tavg는 온도 수준과 범위, chargetime은 충전 시간 비교에 사용한다. 이 값들은 사이클 하나를 요약한 값이므로, 사이클 안에서 전류·전압이 변하는 과정은 다음 페이지의 Cycles 필드로 확인한다.

단위 및 결측값 처리

용량은 Ah, 저항은 Ω, 온도는 °C, 시간은 min으로 해석한다. IR=0은 초기 저항 피쳐에서 측정 결측으로 처리한다. B1의 첫 사이클 QDischarge=0과 1.3 Ah 초과 용량은 열화 곡선과 용량 기울기 계산에서 제외하며, 사이클 번호는 재부여하지 않는다.

DATA AUDIT / CYCLES STRUCTURE

Cycles 필드의 타입·단위 및 데이터 예시

사이클 내부 시계열과 공통 전압축 보간 곡선

`cycles` 의 각 필드는 N 개 사이클을 가리키는 $(N, 1)$ HDF5 참조 배열이다. 아래 데이터 타입은 사이클 하나를 역참조한 실제 수치 배열 기준이다. 원시 측정점 수 M_i 는 사이클마다 달라지며, 공통 전압축 보간 곡선은 1,000점으로 고정된다.

필드	의미	데이터 타입 / 형태	단위	실제 데이터 예시
<code>t</code>	사이클 내 경과 시간	float64 (1, M_i)	min	[0, 0.000383333, 0.000678333, ...]
<code>I</code>	전류 · 양수 충전 / 음수 방전	float64 (1, M_i)	C-rate	[0.469669, 0.676856, 0.83502, ...]
<code>V</code>	전압	float64 (1, M_i)	V	[2.35797, 2.37387, 2.38784, ...]
<code>T</code>	셀 온도	float64 (1, M_i)	°C	[30.7347, 30.7357, 30.7364, ...]
<code>Qc</code>	누적 충전 용량	float64 (1, M_i)	Ah	[2.14966e-06, 2.14966e-06, 2.14966e-06, ...]
<code>Qd</code>	누적 방전 용량	float64 (1, M_i)	Ah	[0, 0, 0, ...]
<code>Qdlin</code>	전압축 보간 방전 $Q(V)$	float64 (1, 1000)	Ah	[-0.000168517, -0.000137733, -0.000106702, ...]
<code>Tdlin</code>	전압축 보간 온도	float64 (1, 1000)	°C	[29.9105, 29.9105, 29.9105, ...]
<code>discharge_dQdV</code>	방전 용량의 전압 미분	float64 (1, 1000)	Ah/V	[-0.001346, -0.000448668, -0.000775646, ...]

예시는 B2-C01의 cycle 10에서 각 배열의 첫 3개 값이며, $M_{10}=1,028$ 이다. `Qdlin`·`Tdlin`·`discharge_dQdV`는 `Vdlin`의 첫 3개 전압과 대응한다. `Qdlin` 시작점의 작은 음수 값은 원본 보간값 그대로 제시하였다.

최종 용량·누적 용량·전압별 용량의 구분

`summary['QDischarge'] [9]` 는 cycle 10의 최종 용량 **하나**다. 참조를 풀어 재구성한 `cycles['Qd'] [9]` 는 같은 사이클의 누적 방전 용량 **시계열**이며, `cycles['Qdlin'] [9]` 는 공통 전압축에 정렬된 **$Q(V)$ 곡선**이다. Q2에는 `summary`의 `QDischarge`, Q3에는 `Qdlin`·`Vdlin`, Q4에는 `I`·`t`·`Qc`를 사용한다.

전류 단위와 시간 가중

원본 `I`는 이미 C-rate 단위이며, 명목 용량 1.1 Ah에서 1C는 1.1 A에 해당한다. 정책 전류 수준과 약 -4C 방전 구간으로 단위를 확인하여 중복 환산하지 않았다. 측정 간격은 일정하지 않을 수 있으므로 평균 전류와 고전류 노출 비율은 `t`의 양의 시간 차이로 가중한다.

DATA AUDIT

데이터 구성 및 전처리 기준

관측 종료를 수명 종료로 오인하지 않기 위한 분석 집합 정의

배치	MAT 파일 날짜	원시	유효	제외
B1	2017-05-12	46	36	10
B2	2018-02-20	47	39	8
B3	2018-04-12	46	43	3




그림 1. 회색은 제외 셀. 오른쪽 점선 0.885 Ah는 라벨 품질 점검용 허용선이며, EOL 정의 자체는 0.88 Ah이다.

수명 라벨의 채택 기준

명목 용량 1.1 Ah의 80%인 **0.88 Ah**를 EOL 기준으로 해석한다. `cycle_life`가 유한하고 마지막 Qd가 ≤ 0.885 Ah인 셀의 원래 라벨을 사용한다. 5 mAh 허용치는 EOL 직전 측정 종료를 반영한다. B1·B3의 라벨은 주로 마지막 기록 수+1, B2는 실제 0.88 Ah 첫 교차 cycle이다. 따라서 B1·B3는 EOL 근접 라벨이며 임계값 교차를 직접 관측한 것은 아니다.

처리	근거
B1 10개 제외	종료 Qd 0.913–1.043 Ah. 계속 살아 있는 셀의 관측 길이를 확정 수명으로 사용하지 않음.
B2 8개 제외	<code>cycle_life</code> 가 NaN인 VarCharge/SLOWCYCLE 셀. 일부 2 Ah대 값도 존재해 통상 프로토콜과 구분.
B3 3개 제외	EOL 미관측 2개 + 저자 공식 로더가 수집 문제를 명시한 MATLAB 38번 셀 1개.
별도 파일 2개 제외	2018-04-03_varcharge: 둘 다 라벨 NaN. 가변 충전 실험으로 분석 대상 배치에서 제외.

선행 연구와의 데이터 구성 차이

분석 대상 Batch 2는 2018-02-20이며, 선행 연구의 Batch 2(2017-06-30)와 다르다. 이에 따라 원본 배치의 셀 병합 및 분할 인덱스 대신 현재 배치 구성을 기준으로 분석 집합과 검증 전략을 정의하였다. B3의 추가 노이즈 제외 기준은 현재 셀의 품질 점검 결과를 적용하였다. [자료 2]

Question 1 · Cycle Life 분포

배치별 수명 분포 및 수명 구간 비율

150–2,300 cycles 공통 범위에서 배치별 수명 분포 비교




그림 2. 100 cycles 간격의 히스토그램. 점선은 500 / 1,000 cycles 기준이다. 유효 라벨 범위는 실제로 392–1,935 cycles다.

배치 / n	평균 ± 표준편차	중앙값	Q25–Q75	최소–최대	<500	>1,000
B1 / 36	788.4 ± 148.7	772.5	681.0–871.5	534–1,074	0 (0.0%)	5 (13.9%)
B2 / 39	565.7 ± 222.2	472.0	439.5–508.5	392–1,186	28 (71.8%)	3 (7.7%)
B3 / 43	1,052.0 ± 313.4	1,002.0	828.0–1,150.5	541–1,935	0 (0.0%)	22 (51.2%)




그림 3. 왼쪽은 셀별 점과 박스플롯, 오른쪽 비율의 분모는 각 배치의 유효 라벨 셀 수. 500·1,000은 중간 그룹에 포함한다.

수명 분포 및 수명 구간 비율 해석

B1은 700–900 부근에 모이고, B2는 400–500 부근에 집중되면서 800–1,200의 긴 꼬리를 갖는다. B3는 넓게 퍼지며 장수명 셀이 51.2%다. 전체는 단수명 $28/118 = 23.7\%$, 장수명 $30/118 = 25.4\%$, 중간 $60/118 = 50.8\%$ 이다.

배치 간 분포 차이는 Kruskal–Wallis $H=53.88$, $p=2e-12$ 로도 나타난다. 이는 차이가 있다는 탐색적 근거이며 충전 조건의 인과 효과 검정은 아니다.

Question 1 · Cycle Life 분포

최단수명 셀 사례 및 이상치 검토

배치별 최단수명 사례와 관측 가능한 원인 단서




그림 4. 각 배치 최단수명 셀의 Qd 추이. 오른쪽은 수명과 초기 용량으로 정규화한 비교다.

셀	수명	프로토콜	Qd(2)	100/2 비	log Var(ΔQ)	Knee
B1-C21	534	5.4C(80%)-5.4C	1.073	0.9894	-3.367	419
B2-C20	392	6C(60%)-3C	1.090	1.0026	-3.292	294
B3-C29	541	3.7C(31%)-5.9C [new]	1.052	0.9830	-3.451	380

최단수명 사례의 특성과 원인 단서

B2-C20 (392 cycles)은 초기 Qd가 1.090 Ah로 낮지 않고, 100사이클에도 0.26% 증가한다. 초기 용량만 보면 정상처럼 보이지만 ΔQ 변화가 크고 약 294사이클 이후 열화가 가속된다. 같은 6C(60%)-3C의 B2-C22도 408사이클이므로 특정 한 셀의 측정 오류만으로 설명하기 어렵다.

B1-C21 (534)은 5.4C를 80% SOC까지 유지하며, 같은 정책의 C22도 559다. **B3-C29 (541)**은 3.7C에서 5.9C로 전환하며, 같은 정책 셀은 541·667·772다. 후반 SOC에서 높은 전류를 쓰는 조건이 가능한 설명이지만, 이 데이터만으로 리튬 도금·SEI 증가 등 물리적 원인을 확정할 수는 없다.

통계적 이상치 기준	결과
배치 내부 Tukey 1.5×IQR 하한	B1 395.25 / B2 336 / B3 344.25 cycles. 하한 아래 셀은 세 배치 모두 0개.
상한 밖 장수명 셀	B1 0개 / B2 9개 / B3 5개. 충전 태그·정책 차이를 먼저 확인하며 자동 삭제하지 않음.

판단

최단수명 셀은 “상대적으로 짧은 사례”이지 통계적 저수명 이상치는 아니다. 타당한 실험 조건에서 나온 짧은 수명은 모델이 배워야 할 정보다. 제조 결함 여부·전극 진단 정보는 제공되지 않았다.

Question 1 · Cycle Life 분포

수명 분포 형태와 배치 내부 집단 비교

누적분포와 배치 내부 집단을 통해 수명 분포의 형태를 확인




그림 5. 왼쪽은 배치별 경험적 누적분포(ECDF), 오른쪽은 B2의 프로토콜 태그별 분포다. 높이는 해당 수명 이하 셀의 누적 비율이다.

배치	평균 - 중앙값	표준편차 / 평균	왜도	800 이하 비율
B1	15.9	18.9%	0.30	55.6%
B2	93.7	39.3%	1.64	82.1%
B3	50.0	29.8%	1.34	14.0%

1. 배치별 분포 형태와 산포

B1은 비교적 좁은 분포다. 평균과 중앙값 차이는 15.9 cycles이고, 변동계수는 18.9%로 가장 낮다. 평균적인 셀과 중앙에 위치한 셀의 수명이 크게 다르지 않다. 반면 **B2는 강한 오른쪽 꼬리**를 가진다. 평균 565.7은 중앙값 472보다 93.7 높으며, 왜도 1.64와 변동계수 39.3%가 이를 뒷받침한다. 평균만 보면 실제 다수 셀의 수명을 길게 해석할 수 있다.

B3는 중심이 길고 장수명 꼬리도 존재한다. 중앙값 1,002, 상위 사분위 1,150.5이며, 1,600 cycles 이상 셀들이 평균을 높인다. 800 cycles 이하 비율은 B1 55.6%, B2 82.1%, B3 14.0%로, 동일한 수명 기준을 적용했을 때 배치 차이가 명확하다.

2. B2의 장수명 꼬리와 태그별 집단 차이

B2의 태그 없음 셀 30개는 평균 453, 중앙값 451로 짧은 수명 구간에 모인다. 반면 newstructure 태그 셀 9개는 평균 941.6, 중앙값 904다. 태그 없음 집단에는 28개의 <500 셀이 있고, 태그 집단에는 없다. 따라서 B2의 분포는 균일한 모집단의 큰 산포만이 아니라, 수명 수준이 다른 두 집단의 혼재로 해석할 수 있다. 태그는 집단을 구분하는 관측 정보이며 차이의 물리적 원인을 직접 증명하지는 않는다.

3. 제외된 셀이 분포 해석에 미치는 영향

B1의 종료 용량이 높은 10개 셀과 B3의 EOL 미관측 2개 셀은 관측 종료 이후에도 수명이 이어질 수 있다. 특히 B3-C24와 C33은 이미 2,189~2,237사이클까지 기록되었지만 EOL은 관측되지 않았다. 따라서 유효 라벨 최대 1,935는 전체 실험의 최대 가능한 수명을 뜻하지 않는다. 위 비율과 누적분포의 모집단은 **유효 수명 라벨을 가진 셀**로 한정된다.

Question 2 · 열화 곡선 및 Knee point

방전 용량 궤적 및 초기 용량 변화

사이클별 방전 용량: 전체 궤적과 초기 100사이클 비교




그림 6. 유호 라벨 118개 셀의 Qd 궤적을 수명 시점까지 표시. 색은 수명(짧음: 보라, 김: 노랑). 점선은 EOL 0.88 Ah.




그림 7. 같은 셀의 초기 100사이클 확대. 초기 용량이 높다고 최종 수명이 긴 것은 아니다.

배치	Qd(100) > Qd(2)	해석
B1	88.9%	초기 활성화·회복과 완만한 변화가 많음
B2	64.1%	다수 단수명 셀도 초기 용량이 증가
B3	83.7%	절대 초기 용량이 낮아도 수명은 긴 편

열화 속도의 비선형 변화

일정하지 않다. 전체 93/118개(78.8%) 셀이 cycle 100에서 cycle 2보다 높은 용량을 보인다. 초기에는 증가 또는 작은 변화, 중반에는 완만한 감소, 후반에는 빠른 감소가 나타난다. 초기 100사이클 직선 기울기를 전체 수명까지 외삽하면 이 비선형 패턴을 놓친다.

곡선 정리 기준

B1 첫 사이클의 0 Ah는 자리 채움 값으로 제외하고, $Q_d \leq 0$ 또는 > 1.3 Ah인 관측점을 가린다. cycle 번호는 재번호화하지 않아 cycle 10·100 대응을 보존한다. 제외 관측점은 0으로 치환하지 않는다.

Question 2 · 열화 곡선 및 Knee point

Knee point 탐색 및 배치별 비교

연속된 두 직선의 변화점으로 탐색한 운영상 Knee




그림 8. 배치별 최단수명 셀. 점선은 연속 구간 회귀, 세로선은 SSE가 최소인 변화점.




그림 9. 왼쪽은 Knee와 수명 관계, 오른쪽은 후기/초기 기울기 절댓값 비. 117/118 셀이 탐색 기준을 충족한다.

배치	Knee 검출 / n	Knee / 수명 중앙값	기울기 비 중앙값
B1	36/36	75.1%	10.2배
B2	39/39	75.0%	10.2배
B3	42/43	79.4%	10.0배

탐색 방법과 해석 범위

cycle 20부터 수명 시점까지 21-point 중앙값 필터로 잡음을 줄이고, 구간 내 20-85% 지점에서 100개의 변화점 후보를 탐색한다. $Qd = a + b \cdot \text{cycle} + c \cdot \max(0, \text{cycle} - k)$ 를 적합해 SSE가 최소인 k 를 선택한다. 초기·후기 기울기가 모두 음수이고, 후기가 2배 이상 가파르며, 단일 직선 대비 SSE가 25% 이상 감소할 때 검출로 표시한다.

Knee 위치는 B1·B2 약 75%, B3 약 79%다. 11·21·41-point 평활화 변경 시 Knee 차이의 중앙값은 0.0 cycles다. 이는 평활화 민감도이며 신뢰구간은 아니다. B3-C07은 약 1.9배로 기준을 충족하지 않아 미검출 처리한다.

Knee는 전체 궤적을 관측한 뒤 정의한 변화점이다. 이 분석에서는 변화점 이전과 이후의 평균 감소 속도를 비교하는 지표로 해석하며, 실제 전극 내부의 단일 반응 시작 시점과 동일하다고 가정하지 않는다.

Question 2 · 열화 곡선 및 Knee point

열화 단계별 용량 유지율 및 감소 속도

초기 용량 증감 · 상대 수명 진행률 · Knee 전후 기울기




그림 10. 왼쪽: 11-point 중앙값 평활화 후 상대 수명축으로 보간한 용량 유지율의 셀별 중앙값·사분위 범위. 오른쪽: 초기 용량 증감률. 상대 수명축은 사후 궤적 비교용이다.

배치	Qd(2) 중앙값	초기 증감률 중앙값	Knee 전 기울기	Knee 후 기울기
B1	1.0784 Ah	0.220%	-0.074	-0.793
B2	1.0954 Ah	0.198%	-0.119	-1.348
B3	1.0656 Ah	0.131%	-0.062	-0.692

기울기 단위는 mAh/cycle. 초기 증감률은 각 셀의 $[Qd(100)/Qd(2)-1]$ 을 계산한 뒤 중앙값을 구했다. Knee 전후 기울기는 연속 구간 회귀 결과의 중앙값이며, 두 중앙값의 비와 셀별 기울기 비 중앙값은 다를 수 있다.

1. 초기 용량 변화와 최종 수명의 관계

초기 증감률 중앙값은 B1 +0.220%, B2 +0.198%, B3 +0.131%다. 수명이 짧은 B2도 초기 용량 자체는 소폭 증가한다. 또한 Qd(2) 중앙값은 B2 1.0954 Ah로 가장 높고, 가장 긴 수명을 보이는 B3는 1.0656 Ah로 가장 낮다. 즉 초기 절대 용량의 순서는 최종 수명 순서와 일치하지 않는다. 단수명 셀이라도 100사이클 시점의 용량 감소가 뚜렷하지 않을 수 있다.

2. 후기 열화의 가속과 감소 속도

Knee 이전 기울기는 -0.062~-0.119 mAh/cycle 범위지만, 이후는 -0.692~-1.348 mAh/cycle로 더 가파르다. B2의 후기 기울기가 가장 음수여서 단위 cycle당 감소가 빠르며, 상대적으로 짧은 수명과 일관된 모습을 보인다. 단, 이는 전체 궤적의 구간 회귀 요약이며 충전 조건의 인과 효과 추정치는 아니다.

배치	수명 50% 시점 유지율	75% 시점	90% 시점	Knee cycle 중앙값
B1	98.6%	95.5%	88.8%	578
B2	99.3%	95.4%	89.3%	342
B3	98.2%	95.8%	90.7%	821

세 배치 모두 수명 절반 지점에는 초기 용량의 약 98~99%가 남고, 75%에는 약 95~96%, 90%에는 약 89~91%가 남는다. 상대 수명축의 공통된 굴곡은 후기 가속을 뒷받침하지만, 실제 cycle 기준 Knee 중앙값은 B2 약 342, B1 약 578, B3 약 821로 차이가 크다. 따라서 "수명 후반에 가속된다"와 "같은 cycle에서 가속된다"는 서로 다른 주장이다.

Question 3 · 초기 $\Delta Q(V)$ 곡선초기 $Q(V)$ 와 $\Delta Q(V)$ 의 수명 그룹별 비교

동일 전압에서 $\Delta Q_{100-10}(V) = Q_{100}(V) - Q_{10}(V)$




그림 11. 각 배치 최단수명 셀의 cycle 10 / 100 방전 $Q(V)$. 두 곡선의 동일 전압 지점끼리 차분한다.




그림 12. 장수명 >1,000 / 단수명 <500 비교. 실선=그룹 중앙값, 음영=셀 간 Q25-Q75. 중간 수명은 이 그림에서 제외.

배치	단수명 n	장수명 n	log Var 중앙값 (단 / 장)
B1	0	5	비교 불가 / -4.059
B2	28	3	-3.446 / -4.271
B3	0	22	비교 불가 / -4.311

초기 ΔQ 곡선의 수명 그룹별 차이

그렇다. 비교 가능한 B2에서는 단수명 그룹의 ΔQ 음의 편차와 전압 구간별 굴곡이 더 크다. 특히 약 2.7~3.2 V 부근에서 차이가 두드러진다. B2의 단수명 그룹 중앙 log 분산은 장수명 그룹보다 0.826 높다(분산 규모 약 6.7배). 다만 장수명 표본은 3개뿐이다.

각 배치 비교의 한계

B1·B3에는 절대 기준 <500 셀이 없으므로 장수명 대 단수명 직접 비교를 만들 수 없다. 다음 페이지에서 각 배치의 하위·상위 사분위 수명 그룹을 보조 비교하되, 절대 수명 <500 / >1,000 기준과 구분한다.

Question 3 · 초기 $\Delta Q(V)$ 곡선

ΔQ 요약 통계와 수명 간 관계

실제 수명과의 연관성, 절대·상대 수명 그룹 비교




그림 13. 배치 내부 수명의 하위·상위 25%를 비교. 이는 상대 수명 구분으로, <500 / >1,000의 대체 정의가 아니다.




그림 14. 초기 ΔQ log 분산과 최종 수명. 세 배치 모두 음의 관계가 나타난다. y축은 로그 스케일.

집합	n	Spearman ρ	Bootstrap 95% 구간	Pearson r vs log 수명
ALL	118	-0.885	-0.922 ~ -0.825	-0.901
B1	36	-0.826	-0.916 ~ -0.658	-0.844
B2	39	-0.709	-0.870 ~ -0.432	-0.918
B3	43	-0.787	-0.893 ~ -0.591	-0.784

118개 셀 모두 `qdlin`의 10·100번 곡선과 `vdlin`을 사용했다. 전압은 3.5→2.0 V의 동일한 1,000점이므로 별도 재보간 없이 차분 가능하다. MATLAB cycle 10은 Python index 9, cycle 100은 index 99이며 summary의 연속 cycle 번호를 확인했다.

추출값	정의 / 사용
$\log_{10} \text{Var}(\Delta Q)$	1,000개 전압점의 표본분산(ddof=1), 단위 Ah ² . 주 피쳐.
$\log_{10} \text{min } \Delta Q / \text{mean}(\Delta Q)$	큰 음의 이동과 곡선 전체 이동량. 분산과 높은 공선성이 있어 대체 후보.
skewness / excess kurtosis	편차의 비대칭과 꼬리 모양. 보조 후보로만 검증.

Question 3 · 초기 $\Delta Q(V)$ 곡선전압 구간별 ΔQ 특성 비교

배치 내부 상대 수명 그룹과 전압 구간별 요약 통계

배치 / 그룹	n	수명 중앙값	$\Delta Q(3.0\text{ V})$	min ΔQ 중앙값	log Var 중앙값
B1 / 하위 25%	9	617.0	-51.9	-56.4	-3.433
B1 / 상위 25%	9	1,014.0	-25.4	-29.1	-4.046
B2 / 하위 25%	10	414.0	-63.4	-64.3	-3.339
B2 / 상위 25%	10	872.5	-19.7	-22.9	-4.231
B3 / 하위 25%	12	804.5	-25.9	-27.9	-4.079
B3 / 상위 25%	11	1,315.0	-15.5	-17.5	-4.439

ΔQ 단위는 mAh. 그룹은 배치별 수명의 $\leq Q_{25}$ / $\geq Q_{75}$ 이며 동률을 포함한다. 따라서 B3 하위 그룹은 12개다. $\Delta Q(3.0\text{ V})$ 는 공통 전압측에서 선형 보간한 셀별 값의 중앙값이다.

1. 용량 총량이 비슷해도 곡선 차이는 크다

B1 하위 그룹의 3.0 V 차분 중앙값은 -51.9 mAh, 상위 그룹은 -25.4 mAh로 절댓값이 약 2배다. B2는 -63.4 대 -19.7 mAh로 약 3.2배, B3는 -25.9 대 -15.5 mAh로 약 1.7배다. 세 배치에서 상대적으로 짧은 셀은 같은 전압에 도달했을 때 누적 방전 용량의 변화가 더 크다. 이 차이는 두 사이클의 최종 방전 용량 차이와 동일한 지표가 아니며, 방전 곡선의 이동과 굴곡을 반영한다.




그림 15. 전압측을 네 구간으로 나누어 각 구간의 ΔQ log 분산과 수명 사이의 Spearman 상관을 계산했다. 구간별 결과도 셀 단위 표본을 사용한다.

2. 전압 구간별 분산과 수명의 관계

2.7~3.2 V 부근에서 그룹 곡선의 음의 굴곡이 시각적으로 크지만, **2.0~2.5 V 구간 분산도** 전체 수명과 $\rho=-0.893$ 의 강한 관계를 보인다. 2.5~3.0 V는 -0.848, 3.0~3.3 V는 -0.857이다. 따라서 곡선의 정보는 눈에 띄는 한 지점에만 집중되어 있지 않다. 반면 3.3~3.5 V는 B3에서 +0.065로 거의 관계가 없어, 모든 전압 구간이 같은 신호를 제공하지는 않는다.

3. ΔQ 요약 통계의 의미와 정보 중복

평균은 곡선의 전체 이동량, 최솟값은 가장 큰 음의 변화, 분산은 전압에 따라 변화량이 달라지는 정도를 요약한다. 짧은 셀에서는 평균과 최솟값도 더 음수이고 분산도 커지므로 세 통계가 함께 움직인다. 전압 구간별 분석은 곡선 차이를 설명하기 위한 탐색 결과이며, 특정 구간을 선택했을 때 독립 검증에서 더 좋은 예측력을 얻는지는 별도 확인이 필요하다.

Question 4 · 충전 조건과 수명

충전 프로토콜별 평균 수명

프로토콜 문자열을 유지한 배치별 평균 수명 비교




그림 16. 점=정책별 평균, 선=min-max, n=셀 수. [new]는 문자열의 newstructure 태그. 선은 신뢰구간이 아니다.

배치	짧은 평균 수명 정책	평균 / n	긴 평균 수명 정책	평균 / n
B1	5.4C(80%)–5.4C	546.5 / 2	4.4C(80%)–4.4C	1,074 / 1
B2	3.6C(9%)–5C	394.5 / 2	5.6C(26%)–4.5C [new]	991.3 / 3
B3	3.7C(31%)–5.9C [new]	660 / 3	4.8C(80%)–4.8C [new]	1,599 / 5

배치별 해석

B1: 8C(15%)–3.6C는 평균 1,008.5지만 8C(35%)–3.6C는 607.5다. 최대 C-rate는 같아도 고전류 적용 SOC 구간이 다르니 수명이 달라진다. **B2:** 같은 숫자 프로토콜에서 [new] 여부에 따른 차이가 크다. **B3:** 4.8C 고정 정책도 가장 긴 평균을 보인다.

충전 속도와 수명의 관계

“최대 C-rate가 높으면 무조건 짧다”는 결론은 데이터와 맞지 않는다. C1·C2·전환 SOC·프로토콜 태그를 함께 보고, n=1 정책의 평균을 일반화하지 않는다. [new]의 물리적 의미는 파일만으로 확인되지 않았으므로 태그로만 해석한다.

Question 4 · 충전 조건과 수명

유효 C-rate 및 실측 충전 패턴

SOC 가중 유효 C-rate와 실측 전류 패턴




그림 17. 0-80% SOC 프로토콜의 유효 C-rate와 수명. B1 $\rho=-0.435$ / B2 $+0.321$ / B3 -0.123 .




그림 18. 각 배치의 최단·최장 셀: cycle 10의 실측 충전 전류. $Q_c \leq 0.88$ Ah 구간의 원본 I(C-rate)를 표시.

$$C_{\text{eff}} = 0.8 / [s/C_1 + (0.8-s)/C_2]$$

s는 프로토콜의 전환 SOC(0-0.8)다. 최대 전류나 단순 산술 평균 대신 구간별 충전 시간에 해당하는 조화 평균으로 비교한다. 이는 이상적인 CC 구간의 값이며 실제 CV·휴지 시간을 포함한 충전 시간과 같지 않다.

B2 동일 숫자 정책	태그 없음 평균 / n	[new] 평균 / n
4.8C(80%)–4.8C	483.6 / 5	871.7 / 3
5.2C(58%)–4C	477.8 / 4	961.7 / 3
5.6C(26%)–4.5C	448.5 / 6	991.3 / 3

혼재된 효과를 구분한다

B2에서 태그 없음 30개 평균 453, [new] 9개 평균 941.6이다. C-rate 관계의 부호 차이는 이런 집단 차이의 영향을 받을 수 있다. 태그 자체의 인과 효과를 확정할 수 없으며, 동일 정책·동일 태그 내 평가를 추가한다.

Question 4 · 충전 조건과 수명

충전 전류와 열화 속도의 상관 분석

충전 조건은 보조 신호이며, 후기 열화는 EDA에만 사용




그림 19. 충전 신호와 수명 / 후기 Qd 기울기의 Spearman 상관. 후기 기울기는 더 음수일수록 용량 감소가 빠르다.

실측 평균 C-rate	수명과 ρ	후기 Qd 기울기와 ρ	관찰
전체	-0.203	-0.335	약한 수명 관계, 높은 전류와 빠른 후기 감소의 연관
B1	-0.446	-0.517	배치 내부에서는 음의 관계가 비교적 뚜렷
B2	+0.406	+0.131	[new] 등 집단 존재; 단순 고속 충전 해석 곤란
B3	-0.119	-0.448	수명 자체보다 후기 기울기와 관련

실측 전류 피쳐 계산

cycle 10~100의 I, t, Qc 에서 양의 충전 전류와 누적 충전량 ≤ 0.88 Ah 구간을 선택한다. 양 끝 평균 전류를 양의 Δt (분)로 가중하고, 두 사이클의 평균을 낸다. 원본 I는 이미 C-rate 단위이므로 추가 환산 없이 시간 가중 평균 C-rate, 표준편차, >5C 시간 비율, 최대 C-rate를 추출한다. 중복 시간·비율의 Δt ·휴지·방전 구간은 제외한다.

B3의 >5C 시간 비율 ↔ 수명 $\rho = -0.191$ 로 약한 음의 관계가 관측된다. 전체 배치 순위 보정 후에는 -0.138 로 약해지므로 강한 단독 수명 신호로 해석하기 어렵다. 다만 이는 실측 초기 충전량 기준이며 프로토콜의 명목 SOC와 완전히 동일하지 않을 수 있다.

전류 패턴과 열화 속도의 관계 해석

B1~B3에서 실측 평균 전류가 높을수록 후기 기울기가 더 음수인 경향이 나타난다. 그러나 B2는 같은 방향을 보이지 않는다. 따라서 충전 전류 패턴과 열화 속도는 연관되지만, 그 관계의 크기와 방향은 배치별 조건을 함께 고려해야 한다. 낮은 후기 기울기는 빠른 용량 감소를 뜻하며, 이를 수명과의 상관 부호와 혼동하지 않아야 한다.

Question 4 · 충전 조건과 수명

프로토콜 태그별 충전 조건 비교

같은 숫자 프로토콜의 비교 · 태그 내부 상관 · 해석 가능한 범위




그림 20. B2의 실측 평균 C-rate와 수명을 태그별로 분리한 산점도, 같은 숫자 정책의 평균 수명 비교. 태그별 표본 수와 관측 범위가 다르다.

B2 집합	n	평균 수명	중앙값	유효 C-rate ↔ 수명 ρ	실측 평균 C-rate ↔ 수명 ρ
B2 전체	39	565.7	472.0	0.321	0.406
B2 태그 없음	30	453.0	451.0	0.207	0.328
B2 [new]	9	941.6	904.0	0.316	-0.283

1. 태그 내부의 전류-수명 상관

태그는 중요한 집단 차이이지만 모든 관계를 설명하지는 않는다. B2 전체의 실측 평균 C-rate 상관은 +0.406이다. 태그 없음 집단 내부에서도 +0.328이므로, 전체의 양의 상관을 태그 존재만의 결과라고 단정할 수 없다. [new] 내부에서는 -0.283으로 방향이 달라지지만 표본이 9개뿐이다. 즉 배치, 태그, 숫자 프로토콜의 차이가 함께 섞인 관찰 결과이며 단일한 충전 속도 효과로 환원하기 어렵다.

2. 동일 프로토콜의 태그별 평균 수명 차이

그렇다. B2의 4.8C 고정 정책은 태그 없음 483.6, [new] 871.7로 약 1.8배 차이가 난다. 5.2C(58%)-4C는 477.8 대 961.7로 약 2.0배, 5.6C(26%)-4.5C는 448.5 대 991.3으로 약 2.2배다. C1-C2-전환 SOC가 같아도 수명이 크게 달라져, 프로토콜 숫자만으로 포착되지 않는 집단 차이가 있음을 보여준다. 태그의 물리적 의미나 나머지 실험 조건이 완전히 통제되었다는 근거는 없다.

3. 충전 속도와 적용 SOC 구간의 관계

B1에서는 유효 C-rate와 수명 $\rho = -0.435$ 가 이 주장과 부합한다. 그러나 8C를 15% SOC까지만 적용한 정책은 평균 1,008.5로, 5.4C를 80%까지 적용한 546.5보다 길다. B3의 4.8C 고정 정책도 평균 1,599로 가장 긴 정책이다. 따라서 이 데이터의 답은 **최대 속도만으로는 결정되지 않으며, 고전류가 어느 SOC 구간에서 얼마나 오래 적용되는지와 셀 집단을 함께 봐야 한다**이다.

실측 평균 전류, 고전류 시간 비율 및 충전 후반의 C2가 서로 다른 측면을 측정한다. 높은 속도와 수명의 관계를 인과적으로 분리하려면 같은 셀 집단에서 SOC 전환과 전류를 통제된 비교가 추가로 필요하다.

Question 5 · 상관관계 및 다중공선성

초기 피처와 Cycle Life의 상관관계

전체 상관, 배치 내부 상관, 배치 보정 상관을 함께 확인




그림 21. 초기 100사이클 피처와 수명 상관. 배치 보정은 피처-수명의 전체 순위에서 배치 평균을 제거한 뒤 계산한 Pearson 상관.

배치 안에서도 유지

ΔQ log 분산의 p 는 B1 -0.826, B2 -0.709, B3 -0.787이다. 배치 보정 후에도 -0.835다. 최단수명 셀을 제외해도 전체 $p=-0.883$ 로 신호가 유지된다.

합쳐서만 강한 신호

Qd(2)의 전체 $p=-0.563$ 이지만 배치별로는 +0.161 / +0.085 / +0.184, 배치 보정 후 +0.011이다. 초기 용량의 차이가 배치의 수명 차이를 반영했을 가능성이 크다.

표본과 통계

IR 관련 피처는 6개 셀의 0값을 결측 처리해 $n=112$, 나머지는 $n=118$ 이다. 상관은 인과 또는 검증된 모델 중요도가 아니다. 전체 상관과 배치 보정 상관의 차이는 서로 다른 실험 집단이 섞일 때 생기는 교란을 보여준다.

Question 5 · 상관관계 및 다중공선성

피처 간 상관 및 다중공선성 진단

상관행렬과 VIF로 확인하고, 중복 피처를 줄인다




그림 22. 피처 간 Spearman 상관. 숫자는 $|p| \geq 0.9$ 인 쌍만 표시. log 분산과 log 표준편차는 정확히 중복이다.

넓은 후보 집합의 VIF

피처	VIF
$\log_{10} \text{Var}(\Delta Q)$	22.38
$\log_{10} \min \Delta Q $	18.46
$\text{mean}(\Delta Q)$	22.06
$Qd(100)/Qd(2)$	12.35
유효 C-rate	11.37
실측 평균 C-rate	11.24

축소 후보 집합의 VIF

피처	VIF
$\log_{10} \text{Var}(\Delta Q)$	2.21
Qd(2)	2.26
Qd 기울기 91-100	1.16
$IR(100)-IR(10)$	1.03
평균 Tmax (2-100)	1.15
>5C 시간 비율	1.15

정확한 중복: $\log \text{Std} = 0.5 \times \log \text{Var}$ 이므로 표준편차를 제거한다. $\log |\min \Delta Q|$ 및 $\text{mean} \Delta Q$ 는 $\log \text{Var}$ 과 $|p| \approx 0.99$ 라 동시에 강제 투입하지 않는다. $Qd(2) \cdot Qd(100)$ 도 $p = 0.961$ 이다.

공선성 진단의 의미

VIF는 한 피처가 다른 피처들의 선형 조합으로 얼마나 설명되는지를 나타낸다. 예를 들어 VIF ≈ 22 인 log 분산은, 다른 피처와 함께 사용할 때 독립적인 정보가 상당 부분 중복된다. 축소 집합의 최대 VIF는 2.26으로 감소한다. 이는 선형 중복이 완화되었다는 결과이며, 각 피처의 수명 예측력이 높다는 뜻은 아니다. 두 표 모두 IR 결측 6개를 제외한 112개 셀에서 계산하였다.

Question 5 · 상관관계 및 다중공선성

배치 보정 전후의 신호 비교

초기 용량의 교란 사례와 여러 신호의 독립성 비교




그림 23. Qd(2)와 수명 산점도: 전체 배치에서는 음의 관계가 보이지만, 전체 순위에서 배치별 평균 순위를 제거하면 거의 사라진다.

신호	전체 Spearman ρ	B1	B2	B3	배치 보정 순위 상관
$\log_{10} \text{Var}(\Delta Q)$	-0.885	-0.826	-0.709	-0.787	-0.835
$\text{mean}(\Delta Q)$	0.858	0.758	0.697	0.743	0.787
Qd(2)	-0.563	0.161	0.085	0.184	0.011
Qd 기율기 91~100	-0.000	0.321	0.354	0.035	0.308
평균 IR (2~100)	-0.447	0.196	-0.199	0.211	-0.153
IR(100)-IR(10)	-0.097	-0.271	0.122	-0.320	-0.173
평균 Tmax (2~100)	0.058	-0.102	-0.136	-0.054	-0.060
>5C 시간 비율	-0.098	-0.122	-0.112	-0.191	-0.138

1. 초기 용량의 전체 상관과 배치 차이

B2는 초기 용량이 상대적으로 높지만 최종 수명은 짧고, B3는 초기 용량이 낮지만 수명은 길다. 이 집단 간 차이로 전체 상관 -0.563 이 형성된다. 그러나 각 배치 내부의 상관은 $+0.085 \sim +0.184$ 로 약하고, 배치 보정 후 $+0.011$ 이다. 따라서 “초기 용량이 클수록 빨리 열화한다”는 결론은 이 상관만으로 뒷받침되지 않는다.

2. 배치 내부에서도 유지되는 ΔQ 신호

$\Delta Q \log$ 분산은 배치 내부에서도 $-0.709 \sim -0.826$ 이고, 배치 보정 후 -0.835 로 강한 관계를 유지한다. 평균 ΔQ 도 보정 후 $+0.787$ 로 남는다. 이는 초기 전압-용량 곡선의 변화가 단순한 배치 평균 차이 이상의 수명 정보를 포함한다는 근거다. 다만 두 통계 사이의 $|\rho| \approx 0.985$ 는 같은 곡선 변화의 상당 부분을 중복 요약한다는 사실도 보여준다.

3. 온도·내부저항 신호의 상관과 한계

초기 평균 IR의 전체 $\rho = -0.447$ 은 배치 보정 후 -0.153 으로 약해진다. 평균 Tmax의 전체 상관은 $+0.058$, 보정 후 -0.060 으로 거의 없으며, 이 데이터에서는 강한 단독 신호가 아니다. IR 변화량은 보정 후 -0.173 , >5C 시간 비율은 -0.138 로 일부 관계가 남지만 ΔQ 분산보다 약하다. 약한 단변량 상관은 정보가 전혀 없다는 뜻은 아니며, 조건에 따라 다른 신호와의 조합이 영향을 줄 수 있다.

MODEL DESIGN / EDA 종합

EDA 결과에 따른 모델 설계 원칙

Q1-Q5의 분석 결론에서 도출한 처리·피처·검증 원칙

EDA에서 확인한 특성	설계상의 문제	대응 전략
Q1 · 단수명 28개가 모두 B2, 배치별 수명 수준 차이	배치 구분만으로 수명을 예측할 위험. 짧은 수명이 없는 학습 집합에서는 외삽 발생.	배치를 입력 대리 변수로 쓰기보다 분할 기준으로 사용. Leave-one-batch-out 및 배치별 오차 보고.
Q1 · 유효 집합에서 검열 셀 제외	유효 라벨 분포가 전체 실험 셀 분포와 다름.	회귀는 유효 라벨 셀만 사용. 검열 셀 활용 시 별도의 생존분석 설계.
Q2 · 초기 증가 후 후기 가속, Knee는 수명 75~79%	초기 Qd 감소율의 직선 외삽이 실제 궤적과 맞지 않음.	초기 곡선 변화를 이용해 총 수명 예측. 전체 궤적의 Knee·후기 기울기·종료 용량은 입력에서 제외.
Q3 · ΔQ 분산의 강한 배치 내부 상관	총 용량만으로 초기 상태 차이를 포착하기 어려움.	공통 전압축 ΔQ100-10의 log 분산을 핵심으로 사용. 다른 통계·구간 피처는 소거 실험으로 비교.
Q4 · C-rate 관계가 배치·태그에 따라 변함	최대 C-rate 하나로 수명 설명이 어려움. 태그 의존성도 존재.	C1·C2·전환 SOC와 실측 패턴을 별도 후보로 검증. >5C 시간 비율은 약한 상관이므로 추가 기여를 검증한 경우에만 사용. 같은 숫자 프로토콜을 묶은 그룹 평가.
Q5 · Qd(2)의 관계가 배치 보정 후 사라짐	전체 상관만으로 피처를 고르면 배치 차이를 학습.	피처 추가 가치를 배치 외 검증에서 확인. 상관 선정·대치·표준화를 학습 fold 안에서 실행.
Q5 · ΔQ 통계와 용량 피처 간 공선성	유사 피처의 중복, 계수 불안정 및 과적합.	log Std 제거. log 분산을 대표로 시작하고 Ridge/Elastic Net과 축소 후보 집합 비교.

해석과 예측의 구분

Knee와 후기 열화 속도는 왜 수명이 달라지는지 설명하는 데 유용하지만, cycle 100 시점에는 아직 관측되지 않은 정보다. 반면 ΔQ100-10, 초기 IR·온도 및 cycle 10·100의 전류 패턴은 예측 시점에 이용할 수 있다. 전체 EDA에서 관측한 상관을 그대로 확정 피처로 간주하지 않고, 검증 과정에서 정보 누수와 추가 기여를 점검한다.

후속 모델링의 우선순위

먼저 단일 ΔQ 분산 모델로 기준 성능을 얻고, 독립성이 다른 피처군을 순차적으로 추가한다. 목표는 변수 수를 늘리는 것이 아니라, 소표본에서도 설명 가능하고 새로운 배치·정책에서 오차가 안정적인 모델을 선택하는 것이다.

MODEL DESIGN / 목표와 피처

예측 목표 및 피처 구성

Prediction time = cycle 100 · Target = log₁₀(Cycle Life)

회귀를 선택한다. 중간 수명 60개(50.8%)도 활용하고, 500·1,000의 임의 경계에서 생기는 정보 손실을 피할 수 있다. 단수명이 모두 B2에 있어 이진 분류는 배치 구분 문제로 바뀔 위험도 있다.

$$y = \log_{10}(L), \text{ 예측 수명 } \hat{L} = 10^{\hat{y}} \text{ cycles}$$

L은 품질 검증된 원본 cycle_life 다. 초기 100사이클의 기록이 완전한 셀로 예측한다. log 변환은 392–1,935의 규모 차이를 완화하고 ΔQ log 분산과의 선형 관계(r=−0.901)를 활용한다. 역변환은 중심 예측이므로 평균 수명을 추정할 경우 bias correction도 training fold 안에서 검토한다.

단계	피처	EDA 근거 / 결정
핵심	log ₁₀ Var(ΔQ100–10)	배치별 강한 음의 상관. 단일 피처 기준 모델부터 시작.
보조: 용량	Qd(2), 기율기(91–100)	초기 상태와 늦은 초기 변화. 배치 보정 관계가 약하므로 유지 여부를 소거 검증.
보조: 저항·온도	IR(100)–IR(10), 평균 Tmax(2–100)	대표성이 다른 신호. IR은 6개 결측, Tmax는 약한 관계이므로 성능 개선 시에만 채택.
보조: 충전 패턴	cycle 10·100의 >5C 시간 비율	B3 내 ρ=−0.191. 약한 보조 신호로, 추가 기여가 검증되는 경우에만 채택.
대체 후보	log min ΔQ , mean ΔQ, skew/kurtosis	분산과 중복되거나 배치 일관성이 약함. 별도 후보 집합으로 비교.
정책 민감도	C1 / C2 / 전환 SOC / [new] 태그	프로토콜 내·외 성능 확인용. 태그는 수명 집단 대리 변수가 될 수 있음.
제외	log Std(ΔQ), Knee, 후기 기율기, n_cycles, 종료 Qd	정확한 피처 중복 또는 전체 수명/종료 조건을 사용한 정보 누수.
식별자 제외	cell ID, 파일명, channel, batch	기본 예측 입력에서 제외. batch는 분할·진단 용도. 배치 입력 포함은 비교 실험으로만 수행.

기본 후보는 작게 시작

핵심 1개 → 용량 보조 → 저항·온도 → 충전 패턴 순으로 피처군을 추가한다. VIF 축소 집합은 6개 피처 후보이며, 최종 선정은 validation 결과로 결정한다.

표본·결측 처리

단위는 셀 1개 = 표 1행이다. IR=0은 측정 결측으로 처리하고 training fold 중앙값 대체 + missing indicator를 검토한다. ΔQ 곡선 결측은 임의 대체하지 않으며 필요 사이클 재추출 또는 대상 제외로 다룬다. 이번 유효 집합은 ΔQ 118/118개가 정상이다.

MODEL DESIGN / 검증 전략

후보 모델 및 검증 전략

소표본·배치 이동·공선성을 반영한 데이터 처리와 후보 모델

순서	후보 모델	선정 근거 / 검증 목적
0	Training median baseline	학습 셀의 수명 중앙값 예측. 모든 모델이 넘어야 하는 기준.
1	단일 피쳐 선형회귀	$\log \text{Var}(\Delta Q) \rightarrow \log \text{Life}$. 가장 강하고 일관된 신호의 설명 가능한 기준.
2	Ridge / Elastic Net	작은 표본, ΔQ 통계의 공선성. StandardScaler와 함께 학습하고 규제 강도를 안쪽 CV로 선택.
3	얇은 Random Forest / Gradient Boosting	프로토콜·전류와의 비선형 상호작용 후보. 깊이·leaf size를 제한하고 선형 모델 대비 이득만 확인.

검증 순서

설정	구체적인 실행	확인할 문제
주 평가	Leave-one-batch-out: B1 / B2 / B3 각각 한 번씩 외부 test로 보류. 학습 82 / 79 / 75개, test 36 / 39 / 43개.	새로운 배치로의 이동. 짧은 수명이 없는 학습 집합으로 B2를 예측하는 외삽 위험 포함.
안쪽 선택	외부 test를 보지 않고 나머지 학습 셀에서 5-fold CV. 정책 반복이 있으면 GroupKFold를 우선.	스케일링·대치·피쳐 선택·튜닝을 training fold 안에만 fit.
보조 평가	수명 구간·배치 균형을 고려한 반복 셀 단위 split. 동일 셀의 사이클을 다른 split에 넣지 않음.	동일 분포에서 예측이 가능한지와 배치 외 성능을 구분.
정책 외 평가	숫자 정책(C1,s,C2)로 group 생성. 태그가 달라도 같은 숫자 정책은 같은 group으로 보류.	프로토콜 복제와 조건 기억에 의한 낙관적 성능 방지.
소거 / 민감도	ΔQ 만 vs 용량 추가 vs IR/T 추가 vs 전류 추가. [new] 포함/제외, 짧은 셀 제외, B3 수집 문제 셀 포함 결과 비교.	피쳐의 추가 가치와 이상치·태그 의존성 확인.

성능 보고와 최종 결정

원래 cycles 단위의 MAE·RMSE·MAPE를 전체와 배치별로 보고한다. $\log$ RMSE, R^2 , 실제-예측 산점도 및 잔차 vs 수명·배치·프로토콜도 함께 점검한다. 작은 fold에서 R^2 가 불안정할 수 있어 MAE를 주 지표로 둔다. 사전 기준은 baseline 대비 개선, 배치별 큰 실패 감소, 간단한 모델 우선이다.

최종 채택 원칙

외부 배치 test를 사용해 튜닝하거나 피쳐를 확정하지 않는다. 세 배치만 있어 일반화 불확실성이 크므로 fold별 결과를 숨기지 않는다. 검열 셀 활용이 필요해지면 회귀 라벨을 임의 보정하는 대신 별도의 생존분석으로 확장한다. 후속 모델링 단계에서는 이러한 기준에 따라 후보 모델의 성능을 평가한다.

APPENDIX A / 제외 셀 목록

분석 제외 셀 및 측정 품질

셀 번호 C01은 원본 MATLAB 1번: Python index + 1

셀	원본 수명	관측 cycle 수	종료 Qd	제외 사유
B1-C01	1,190	1189	1.0262	종료 용량이 EOL에서 멀다
B1-C02	1,179	1178	1.0382	종료 용량이 EOL에서 멀다
B1-C03	1,177	1176	1.0433	종료 용량이 EOL에서 멀다
B1-C04	1,226	1225	0.9709	종료 용량이 EOL에서 멀다
B1-C05	1,227	1226	1.0220	종료 용량이 EOL에서 멀다
B1-C09	879	878	0.9690	종료 용량이 EOL에서 멀다
B1-C11	906	905	0.9610	종료 용량이 EOL에서 멀다
B1-C13	902	901	0.9131	종료 용량이 EOL에서 멀다
B1-C14	897	896	0.9231	종료 용량이 EOL에서 멀다
B1-C23	891	890	0.9633	종료 용량이 EOL에서 멀다
B2-C23	—	920	1.0556	NaN: VarCharge / SLOWCYCLE
B2-C24	—	1152	0.9782	NaN: VarCharge / SLOWCYCLE
B2-C36	—	423	0.8811	NaN: VarCharge / SLOWCYCLE
B2-C37	—	280	0.8811	NaN: VarCharge / SLOWCYCLE
B2-C38	—	101	2.1693	NaN: VarCharge / SLOWCYCLE
B2-C39	—	101	2.1654	NaN: VarCharge / SLOWCYCLE
B2-C40	—	434	0.8812	NaN: VarCharge / SLOWCYCLE
B2-C41	—	459	0.8802	NaN: VarCharge / SLOWCYCLE
B3-C24	—	2189	0.9370	NaN + 종료 용량 >0.885
B3-C33	—	2237	0.9739	NaN + 종료 용량 >0.885
B3-C38	1,390	1389	0.8805	공식 수집 문제 지정

제외 합계 **21개**: B1 10 / B2 8 / B3 3. 별도 2018-04-03 VarCharge 2개는 주 분석 집합 139개에 포함하지 않았다. 해당 파일의 관측 길이는 813 / 240이며 수명은 둘 다 NaN이다.

측정 품질 점검

B1의 cycle 1 Qd=0은 정상 초기 용량으로 해석하지 않는다. 1.3 Ah 초과 값도 용량 곡선·기울기에서 제외한다. 초기 IR 누락은 B2-C42~C47의 6개 셀로, 수명 라벨을 버리지 않고 IR 피쳐만 결측 처리했다. 초기 Q(V)는 유효 집합 모두 1,000점 공통 전압측·유한값·용량 크기 검사를 통과했다.

APPENDIX B / 분석 방법 및 참고문헌

통계 분석 방법 및 참고문헌

상관계수 · Bootstrap · 다중공선성 진단의 계산 기준

통계와 한계

상관은 기본적으로 Spearman ρ (동순위 평균 순위)이며, log 피처와 log 수명의 선형성은 Pearson r 로 보조 확인했다. 배치 보정은 전체 순위의 배치 평균을 제거한 잔차 상관이다. Bootstrap 구간은 셀 단위 2,000회 복원 추출, seed=20261001의 percentile 95% 구간이다. 전체 bootstrap은 배치를 고정한 총화 추출이 아니며 배치별 구간도 함께 제시했다.

전압점 1,000개는 통계적 독립 표본이 아니다. ΔQ 피처의 표본분산은 곡선의 형태 요약값이며 수명 상관의 표본 단위는 셀이다. 상관 검정의 p값은 다중검정 미보정 탐색값이다. VIF는 표준화한 complete-case 행에서 각 피처를 다른 피처에 선형회귀해 $1/(1-R^2)$ 로 계산한다.

검열 셀 제외는 배치의 수명 분포에 선택 편향을 유발할 수 있다. B1의 추가 관측 자료가 없어 수명 라벨을 병합하지 않았으며, 수집 문제가 확인된 B3-C38을 제외하였다. 분석 집합은 선행 연구의 124개 셀과 다르므로, 연구 간 수치 비교 시 데이터 구성 및 전처리 기준의 차이를 고려해야 한다.

참고문헌

1. [분석 주제] DS Mini Project · DAY 1 — 배치별 EDA 및 모델 설계 전략 수립.
2. [자료 1] Severson et al., Nature Energy (2019) — 명목 용량, 80% EOL 및 ΔQ 기반 초기 수명 예측 방법.
3. [자료 2] 저자 공식 LoadData.m — 원래 배치 날짜, 계속 측정 병합, B3 MATLAB 38번의 수집 문제 확인.
4. [자료 3] 저자 공식 데이터 처리 저장소 — descriptor / summary / cycle 구조와 Qdlin 설명.